P300 Vision Safety — Dimensionamento de Servidor (Capacity)

Versão: 2.0, revisada com a prova de carga **Referências:** P300_Vision_Safety_SRS_v1.0.md · benchmark_capacity.md **Escopo:** até 100 câmeras IP simultâneas **Data:** 10/11/2026

> **Resumo:** para 100 câmeras com 99,5% de disponibilidade, recomenda-se **2 servidores ativo-ativo**, cada um com:
>
> - **1× NVIDIA RTX PRO 4000 Blackwell 24 GB** (alternativa: RTX 4000 Ada 20 GB ou L4 24 GB, com menos folga no pico);
> - **32 núcleos** e **128 GB de RAM**;
> - armazenamento de evidências de 8 a 16 TB úteis.
>
> Cada nó atende 50 câmeras e assume as 100 em modo degradado se o outro cair.
>
> **Pré-requisito de software:** o NMS (filtragem das detecções) precisa rodar dentro da engine TensorRT, e o modelo de EPI precisa ter poucas classes. Sem isso, o pipeline usa o dobro de GPU e cada nó precisaria de 2 GPUs (seção 3.3).

---

1. O que mudou em relação à versão 1.0

Tema	v1.0 (estimativa)	v2.0 (medido na RTX 5080)
Base de cálculo da GPU	TFLOPS teóricos, 20% de aproveitamento	Tempo de GPU medido por câmera: 4,5 ms (2 pessoas) e 7,3 ms (5 pessoas)
INT8	ganho de cerca de 2×	**sem ganho**; usar FP16
Gargalo	GPU	**NMS em Python** (a GPU ficou em 49% nas falhas)
Decode	NVDEC recomendado	**CPU como padrão.** NVDEC custa cerca de 50 MB de VRAM por câmera e só funciona bem com o pipeline num único processo por GPU.
VRAM	de 6 a 10 GB	**6,5 GB medidos**; não é mais critério de escolha

Tema	v1.0 (estimativa)	v2.0 (medido na RTX 5080)
GPU recomendada	1× L4 por nó	**1× RTX PRO 4000 Blackwell** por nó (mesma arquitetura da GPU testada, mais folga no pico)
CPU	32 núcleos	confirmado: 100 câmeras usaram 77% de um i9-14900KF

---

2. Requisitos da SRS e premissas

2.1 Impacto dos requisitos da SRS

Requisito da SRS	Efeito no capacity
Confirmação de 20 s por timestamp (RN-001, RN-002)	Pose a 5 fps e EPI a cerca de 2 avaliações por segundo por pessoa bastam (de 20 a 40 amostras por violação). No modo degradado, 3 fps e 1 Hz ainda dão 20 amostras.
EPIs de vidraria: óculos, luvas, calçado (seção 4; seção 13.1)	Stream 1080p na origem e avaliação em 2 estágios: pose na cena e EPI no recorte de cada pessoa.
Estado "indeterminado" (RN-005)	Modelo de pose (`yolov8s-pose`) para saber se mãos, pés e rosto estão visíveis.
ROI por câmera (RF-015)	Só pessoas dentro da zona vão ao estágio de EPI, o que reduz carga.
Visualização ao vivo independente (CA-007, RF-066)	Repasse do stream sem recodificar (MediaMTX ou go2rtc), com as caixas desenhadas no navegador.
99,5% de disponibilidade (RNF-001)	2 nós ativo-ativo.
Não perder ocorrência (RNF-006)	PostgreSQL replicado e fila persistente.

Requisito da SRS	Efeito no capacity
Evidência com hash e retenção (RNF-012, RF-081)	MinIO replicado, com o clipe copiado do stream original.

2.2 Premissas operacionais

A seção 14.1 da SRS deixa estas decisões pendentes com o cliente:

- 100 câmeras, 1080p, H.264 ou H.265, 15 fps, de 2 a 4 Mbps.
- Em média 2 pessoas por câmera e pico de 5.
- De 5 a 50 ocorrências por câmera por dia.
- Cerca de 10,6 MB de evidência por ocorrência (2 imagens e um clipe de 20 s).
- Retenção de 90 a 180 dias.

2.3 Premissas de software (derivadas da prova de carga)

1. **NMS embutido na engine TensorRT** (`export(nms=True)` ou o plugin EfficientNMS).
2. **Modelo de EPI com 4 a 8 classes**, da classe "s" (custo de rede igual ao `yolov8s`).
3. **Um processo de inferência por GPU, com batching entre câmeras** (batch de 16 a 32), em **FP16**.
4. **Decode na CPU**, em processos de captura de 6 a 12 câmeras cada, convertendo para imagem só os frames amostrados.

---

3. Base de cálculo

3.1 Custo medido por câmera (RTX 5080)

Dados detalhados no benchmark_capacity.md.

Componente	2 pessoas	5 pessoas
Rede pura (pose 5 fps + EPI 2 Hz por pessoa)	4,5 ms de GPU/s	7,3 ms de GPU/s
Com NMS na GPU, +15% de margem (base deste documento)	**5,2 ms/s**	**8,4 ms/s**

Componente	2 pessoas	5 pessoas
Com o NMS em Python atual (medido)	8,4 ms/s	15,6 ms/s
Modo degradado (pose 3 fps, EPI 1 Hz), com margem	2,9 ms/s	4,5 ms/s

3.2 Conversão para GPUs de servidor

O fator abaixo é o desempenho relativo a uma RTX 5080 nesta carga. **São estimativas por banda de memória e FP16 tensor, ainda não medidas.** A seção 7 prevê a validação.

GPU	VRAM	Fator vs. RTX 5080	Observação
RTX 2000 Ada	16 GB	0,20 a 0,25	70 W, para fases pequenas
L4	24 GB	0,40 a 0,50	Passiva, 72 W, exige chassi com fluxo de ar
RTX 4000 Ada	20 GB	0,40 a 0,50	Blower, 130 W, slot simples
RTX PRO 4000 Blackwell	24 GB	**0,60 a 0,70**	Blower, slot simples, mesma arquitetura da GPU testada

Uso da GPU = câmeras × custo por câmera ÷ fator ÷ 1.000 ms.

3.3 Uso de GPU por nó

Valores calculados com o fator no meio da faixa (0,45 e 0,65). Meta: até 70% na média e até 90% no pico.

Cenário	RTX 4000 Ada / L4	RTX PRO 4000 Blackwell
50 câmeras, média (2 pessoas)	58%	**40%**
50 câmeras, pico (5 pessoas)	**93%** (no limite)	**65%**
100 câmeras degradado, média	64%	**45%**
100 câmeras degradado, pico	**100%** (não cabe)	**69%**

Cenário	RTX 4000 Ada / L4	RTX PRO 4000 Blackwell
50 câmeras com NMS em Python, média	93%	65%
50 câmeras com NMS em Python, pico	173% (não cabe)	120% (não cabe)

Conclusões:

- A **RTX PRO 4000 Blackwell** cumpre todos os cenários com folga, inclusive o failover de 100 câmeras.
- A **RTX 4000 Ada ou a L4** cumprem a operação normal, mas ficam no limite no pico e **não aguentam o failover no pico**.
- **Sem o NMS na GPU, nenhuma GPU única por nó atende o pico.** É requisito de software antes da implantação.

3.4 CPU

Medido no i9-14900KF (32 threads):

Cenário	Uso medido
Decode de 100 câmeras	57%
Pipeline completo, 50 câmeras	32%
Pipeline completo, 100 câmeras	77%

Estima-se que o i9-14900KF equivale a 24 a 28 núcleos de servidor (EPYC Zen 4) nesta carga. Isso dá:

- 50 câmeras: de 8 a 10 núcleos;
- 100 câmeras (failover): de 19 a 22 núcleos;
- mais API, PostgreSQL, MinIO e observabilidade: de 4 a 6 núcleos.

32 núcleos por nó dá de 40% a 50% de uso na operação normal e cerca de 80% no failover.

Uma alavanca opcional: configurar as câmeras a **10 fps** em vez de 15 reduz o decode em 33%, sem afetar a inferência (pose a 5 fps e EPI a cerca de 2 Hz continuam possíveis).

3.5 VRAM

Item	Medido / estimado
Engines TensorRT (pose + EPI, batch 32, com contextos)	cerca de 4,5 GB
Contexto CUDA, buffers e PyTorch	cerca de 2 GB
Total por GPU, com decode na CPU	**cerca de 6,5 GB** (independe do número de câmeras)
Com NVDEC (opcional)	mais cerca de 50 MB por câmera: +2,5 GB (50) ou +5 GB (100)

As GPUs recomendadas têm de 20 a 24 GB. **A VRAM sobra e não é critério de escolha.** Batch 16 em vez de 32 reduz cerca de 1 GB, com perda de throughput menor que 3%.

3.6 RAM

A prova não mediu a RAM de forma conclusiva. Mantida a estimativa da v1.0:

Componente	Memória
Inferência	8 GB
Workers de captura	15 GB
Buffers de decode	6 GB
Buffer de pré-alerta comprimido	1 GB
PostgreSQL	16 GB
MinIO	4 GB
Observabilidade	8 GB
SO e cache	16 GB
Total	**cerca de 75 GB no failover; 128 GB por nó**

3.7 Disco de evidências

100 câmeras × 10,6 MB por ocorrência:

Ocorrências por câmera por dia	Por dia	90 dias	180 dias
5	5,3 GB	0,5 TB	1 TB
20	21 GB	1,9 TB	3,8 TB
50	53 GB	4,8 TB	9,5 TB

Somar de 1 a 2 TB para vídeos de validação e retreino (RF-031) e menos de 200 GB por ano de banco, auditoria e logs. A gravação é inferior a 1 MB/s, então **HDD em RAID6** atende as evidências.

3.8 Rede

- Entrada: de 200 a 400 Mbps para 100 câmeras.
- Visualização: cerca de 4 Mbps por câmera assistida.
- **2× 10 GbE por nó**, com as câmeras numa VLAN dedicada.

---

4. Configuração recomendada

Opção A — 2 nós ativo-ativo (recomendada, atende 99,5%)

Operação normal: 50 câmeras por nó. Failover: 100 câmeras num nó, com pose a 3 fps e EPI a 1 Hz.

Item	Por nó
CPU	1× 32 núcleos (AMD EPYC 9355P / 9354P ou Intel Xeon 6530)
RAM	128 GB DDR5 ECC (4× 32 GB)
GPU	**1× NVIDIA RTX PRO 4000 Blackwell 24 GB**
SO e aplicação	2× 960 GB NVMe em RAID1
PostgreSQL	2× 1,92 TB NVMe em RAID1, com replicação entre os nós
Evidências	4× 8 TB HDD em RAID6 (cerca de 16 TB úteis), com MinIO replicado entre os nós

Item	Por nó
Rede	2× 10 GbE
Outros	Fonte redundante, BMC/IPMI, suporte NBD

Incluir backup externo de evidências e banco, e nobreak.

Alternativa de menor custo: RTX 4000 Ada 20 GB ou L4 24 GB por nó. Atende a operação normal (58% na média e 93% no pico). No failover, porém, só sustenta 100 câmeras com até 3 ou 4 pessoas por câmera (de 76% a 88% de GPU); com 5 pessoas chega a 100%, e seria preciso reduzir ainda mais a taxa. **Só é recomendável se o cliente aceitar essa restrição no modo degradado.**

Opção B — 1 nó (mais barata, não garante 99,5%)

Item	Configuração
CPU	1× 32 núcleos
RAM	128 GB
GPU	**2× RTX PRO 4000 Blackwell 24 GB** (50 câmeras por GPU)
Disco	Igual à Opção A, com o dobro de evidências (sem a réplica do outro nó)
Rede	2× 10 GbE

Sobrevive à falha de uma GPU (a outra assume 100 câmeras em modo degradado), mas não à da placa-mãe, da fonte ou de uma manutenção.

Fases menores

Câmeras	GPU	Uso de GPU (média / pico)	CPU	RAM
até 25	1× RTX 2000 Ada 16 GB	58% / 93%	16 núcleos	64 GB
até 25 (com folga)	1× RTX 4000 Ada 20 GB	29% / 47%	16 núcleos	64 GB
até 50	1× RTX PRO 4000 Blackwell 24 GB	40% / 65%	24 núcleos	96 GB

Câmeras	GPU	Uso de GPU (média / pico)	CPU	RAM
até 100	Opção A ou B			

5. Modo degradado (failover)

Parâmetro	Normal	Degradado
Pose por câmera	5 fps	3 fps
EPI por pessoa	cerca de 2 Hz	1 Hz
Amostras na janela de 20 s	de 20 a 40	20
Latência esperada do alerta	menos de 1 s	de 1 a 2 s (dentro do RNF-002, 3 s)

A troca de modo deve ser automática ao detectar a queda do outro nó, e precisa gerar um evento operacional (RN-009).

6. Fatores que podem alterar o dimensionamento

1. **Pessoas por cena.** É a variável que mais pesa na GPU. Câmeras com mais de 5 pessoas simultâneas aumentam a carga linearmente.
2. **NMS fora da GPU.** Mantendo o NMS em Python, a carga de GPU dobra (seção 3.3).
3. **Modelo de EPI maior que a classe "s"** (por exemplo, "m"): o custo do estágio de EPI aumenta de 2 a 3×.
4. **Câmeras 4 MP ou H.265:** mais decode e rede, sem efeito relevante na GPU.
5. **Fator de conversão das GPUs:** estimado, não medido. Se a RTX PRO 4000 Blackwell render abaixo de 0,55×, o failover no pico fica no limite.

7. Validações antes da compra

1. **Implementar o NMS na engine** e repetir o `e2e` na RTX 5080. Meta: aproximar-se da capacidade pura (cerca de 150 câmeras na média).
2. **Repetir a prova com gravações reais** da planta (`--videos`) e com o modelo de EPI treinado.
3. **Medir a GPU escolhida** (RTX PRO 4000 Blackwell ou RTX 4000 Ada), por empréstimo, demonstração ou instância em nuvem, para substituir o fator estimado da seção 3.2.
4. **Medir a RAM real** dos processos de captura e inferência durante o `e2e` .